

# (algebra practice). Անկյունագծայնացում և SVD

- [1. Մատրիցների անկյունագծայնացում](#)
- [2. Մատրիցի ռանգ \(Rank\)](#)
- [3. Եզակի արժեքների վերլուծություն \(SVD\)](#)
- [4. Գործնական օրինակների լուծում](#)
- [5. Կիրառություն. Կեղծ հակադարձ մատրից \(Pseudo-inverse\)](#)
- [Մուր-Պենրոուզի կեղծ հակադարձ մատրից \( \$A^+\$ \)](#)
- [Կիրառություն. Լավագույն մոտարկման խնդիրը](#)
- [Գործնական օրինակի լուծում](#)

## 1. Մատրիցների անկյունագծայնացում

### 1.1. Սահմանում

$A$  քառակուսի մատրիցը կոչվում է **անկյունագծայնացվող**, եթե այն նման է որևէ անկյունագծային  $D$  մատրիցի:

$$A = PDP^{-1}$$

որտեղ  $D$ -ն անկյունագծային մատրից է, իսկ  $P$ -ն՝ հակադարձելի մատրից:

### 1.2. Մատրիցի աստիճանի հաշվում

Անկյունագծայնացումը թույլ է տալիս հեշտությամբ հաշվել մատրիցի բարձր աստիճանները:

$$A^2 = (PDP^{-1})(PDP^{-1}) = PD(P^{-1}P)DP^{-1} = PD^2P^{-1}$$

Ընդհանուր դեպքում  $A^n = PD^nP^{-1}$ :

### 1.3. Սիմետրիկ մատրիցներ

Եթե  $A$ -ն սիմետրիկ է ( $A = A^T$ ), ապա այն անկյունագծայնացվում է **օրթոգոնալ**  $P$  մատրիցի միջոցով:

Քանի որ օրթոգոնալ մատրիցի համար  $P^{-1} = P^T$ , ապա՝

$$A = PDP^T$$

### 1.4. Հակադարձ մատրիցի սեփական արժեքները

Եթե  $Ax = \lambda x$  և  $\lambda \neq 0$ , ապա  $A^{-1}$  մատրիցի սեփական արժեքը  $1/\lambda$  է:

Ապացույց.

$$Ax = \lambda x \implies A^{-1}(Ax) = A^{-1}(\lambda x) \implies Ix = \lambda A^{-1}x \implies A^{-1}x = \frac{1}{\lambda}x$$

## 2. Մատրիցի ռանգ (Rank)

### 2.1. Սահմանում

$A \in M_{m \times n}$  մատրիցի **տողային ռանգ** է կոչվում այդ մատրիցի առավելագույն քանակով գծորեն անկախ տողերի քանակը:

### 2.2. Հիմնական թեորեմ

Կամայական մատրիցի ռանգն ըստ տողերի հավասար է այդ մատրիցի ռանգին ըստ սյուների:

$$\text{rank}_{\text{row}}(A) = \text{rank}_{\text{col}}(A) = \text{rank}(A)$$

$$\text{Եւալ} \text{ rank}(A) = \text{rank}(A^T):$$

## 3. Եզակի արժեքների վերլուծություն (SVD)

### 3.1. Թեորեմ

Կամայական  $A \in M_{m \times n}$  մատրիցի համար գոյություն ունեն  $U \in M_{m \times m}$  և  $V \in M_{n \times n}$  օրթոգոնալ մատրիցներ և  $\Sigma \in M_{m \times n}$  անկյունագծային տեսքի մատրից այնպես, որ՝

$$A = U \Sigma V^T$$

- $U$ -ի սյուները  $AA^T$  մատրիցի սեփական վեկտորներն են:
- $V$ -ի սյուները  $A^T A$  մատրիցի սեփական վեկտորներն են:
- $\Sigma$ -ի անկյունագծային տարրերը ( $\sigma_i$ ) կոչվում են **եզակի արժեքներ** և  $\sigma_i = \sqrt{\lambda_i}$ , որտեղ  $\lambda_i$ -ն  $A^T A$ -ի սեփական արժեքներն են:

### 3.2. Երկրաչափական մեկնաբանություն

SVD-ն ներկայացնում է գծային ձևափոխությունը որպես երեք քայլ՝ պտույտ ( $V^T$ ), ձգում ( $\Sigma$ ) և նորից պտույտ ( $U$ ): Միավոր շրջանագիծը վերածվում է էլիպսի, որի առանցքները  $\sigma_i u_i$  վեկտորներն են:

## 4. Գործնական օրինակների լուծում

**Խնդիր 256.  $A^{10}$ -ի հաշվում**

Տրված է  $A = \begin{pmatrix} 1 & 0 \\ -1 & 2 \end{pmatrix}$ :

1. **Սեփական արժեքներ.**  $\det(A - \lambda I) = (1 - \lambda)(2 - \lambda) = 0 \implies \lambda_1 = 1, \lambda_2 = 2$ :
2. **Անկյունագծայնացում.**  $A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}$ :
3. **Աստիճան.**  $A^{10} = PD^{10}P^{-1} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1^{10} & 0 \\ 0 & 2^{10} \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ -1023 & 1024 \end{pmatrix}$ :

**Խնդիր.  $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}$  մատրիցի SVD վերլուծությունը**

1. **Հաշվում ենք  $A^T A$ .**

$$A^T A = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

2. **Սեփական արժեքներ.**  $\lambda_1 = 3, \lambda_2 = 1$ :
3. **Եզակի արժեքներ.**  $\sigma_1 = \sqrt{3}, \sigma_2 = 1$ :
4.  **$V$  մատրից (սեփական վեկտորներ).**  $v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, v_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$ :
5.  **$U$  մատրից.** Հաշվվում է  $AA^T$ -ի սեփական վեկտորների միջոցով:

$$U = \begin{pmatrix} 2/\sqrt{6} & 0 & -1/\sqrt{3} \\ 1/\sqrt{6} & 1/\sqrt{2} & 1/\sqrt{3} \\ 1/\sqrt{6} & -1/\sqrt{2} & 1/\sqrt{3} \end{pmatrix}$$

6. **Վերջնական տեսք.**  $A = U \Sigma V^T$ :

**5. Կիրառություն. Կեղծ հակադարձ մատրից (Pseudo-inverse)**

Եթե  $Ax = b$  համակարգը լուծում չունի, փնտրում ենք այնպիսի  $x_0$ , որ  $\|Ax_0 - b\|$  լինի մինիմալ:

Լուծումն է՝  $x_0 = A^+b$ , որտեղ  $A^+$  կոչվում է Մուր-Պենրոուզի կեղծ հակադարձ մատրից:

**Մուր-Պենրոուզի կեղծ հակադարձ մատրից ( $A^+$ )**

Երբ մատրիցը քառակուսի չէ կամ հակադարձելի չէ, մենք օգտագործում ենք կեղծ հակադարձ մատրիցը:

Եթե  $A \in M_{m \times n}$ , ապա  $A^+ \in M_{n \times m}$ :

## Հաշվարկման բանաձևը SVD-ի միջոցով

Եթե հայտնի է մատրիցի SVD վերլուծությունը՝  $A = U\Sigma V^T$ , ապա կեղծ հակադարձը հաշվվում է հետևյալ կերպ.

$$A^+ = V\Sigma^+U^T$$

որտեղ  $\Sigma^+$ -ը ստացվում է  $\Sigma$ -ից՝ անկյունագծային տարրերը փոխարինելով իրենց հակադարձներով ( $1/\sigma_i$ ), իսկ մատրիցը տրանսպոզացվում է:

## Կեղծ հակադարձի հատկությունները (Պենրոուզի պայմաններ)

$A^+$  մատրիցը միակն է, որը բավարարում է հետևյալ 4 պայմաններին.

1.  $AA^+A = A$
2.  $A^+AA^+ = A^+$
3.  $(AA^+)^T = AA^+$  (սիմետրիկություն)
4.  $(A^+A)^T = A^+A$  (սիմետրիկություն)

## Կիրառություն. Լավագույն մոտարկման խնդիրը

Եթե  $Ax = b$  համակարգը չունի ճշգրիտ լուծում (օրինակ՝ երբ հավասարումների քանակը շատ է անհայտներից), մենք փնտրում ենք այնպիսի  $x_0$  վեկտոր, որը նվազագույնի է հասցնում սխալը:

$$\|Ax_0 - b\| \rightarrow \min$$

Այս լավագույն մոտարկումը տրվում է հետևյալ բանաձևով.

$$x_0 = A^+b$$

## Գործնական օրինակի լրիվ լուծում

Տրված է.  $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}$  և  $b = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$ :

### Քայլ 1. Գտնել SVD բաղադրիչները

- Սեփական արժեքներ ( $A^T A$ ).  $\lambda_1 = 3, \lambda_2 = 1$ :
- Եզակի արժեքներ.  $\sigma_1 = \sqrt{3}, \sigma_2 = 1$ :

- $\Sigma^+$  մատրից.  $\Sigma^+ = \begin{pmatrix} 1/\sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$ :

## Քայլ 2. Հաշվել $A^+$

Բազմապատկելով  $V\Sigma^+U^T$  մատրիցները, ստանում ենք  $A^+$  կեղծ հակադարձը:

$$A^+ = \begin{pmatrix} 1/3 & -1/3 & 2/3 \\ 1/3 & 2/3 & -1/3 \end{pmatrix}$$

## Քայլ 3. Գտնել լավագույն մոտարկումը ( $x_0$ )

$$x_0 = A^+b = \begin{pmatrix} 1/3 & -1/3 & 2/3 \\ 1/3 & 2/3 & -1/3 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}:$$

- $x_{0_1} = 1/3 - 2/3 + 6/3 = 5/3$
- $x_{0_2} = 1/3 + 4/3 - 3/3 = 2/3$   $x_0 = \begin{pmatrix} 5/3 \\ 2/3 \end{pmatrix}$ :

## Քայլ 4. Ստուգում և սխալի հաշվում

Հաշվում ենք  $Ax_0$  արտադրյալը և համեմատում  $b$ -ի հետ.

$$Ax_0 = \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 5/3 \\ 2/3 \end{pmatrix} = \begin{pmatrix} 7/3 \\ 2/3 \\ 5/3 \end{pmatrix}$$

Սխալը՝  $\|Ax_0 - b\|^2 = (7/3 - 1)^2 + (2/3 - 2)^2 + (5/3 - 3)^2 = \frac{16}{9} + \frac{16}{9} + \frac{16}{9} = \frac{48}{9} = \frac{16}{3}$ : Սա այն նվազագույն հնարավոր սխալն է, որը կարող ենք ստանալ:

**Ինչպես է  $A^+$  մատրիցը օգնում լուծել Գծային Ռեգրեսիայի խնդիրները տվյալների գիտության մեջ:**


Գծային ռեգրեսիան տվյալների գիտության (Data Science) ամենահիմնարար գործիքներից է, և **կեղծ հակադարձ մատրիցը ( $A^+$ )** հանդիսանում է դրա մաթեմատիկական «սիրտը»: Ահա թե ինչպես է այն աշխատում գործնականում.

### 1. Խնդրի Էությունը. Տվյալների գերբեռնվածություն

Պատկերացրեք՝ դուք ունեք տան գների վերաբերյալ տվյալներ (քառակուսի մետր, սենյակների քանակ) և ուզում եք կանխատեսել գինը:

- Դուք ունեք հազարավոր տվյալներ (տողեր), բայց ընդամենը մի քանի բնութագիր (սյուներ):
- Սա ստեղծում է **գերորոշված համակարգ** ( $m > n$ ), որտեղ հավասարումների քանակը շատ ավելին է, քան անհայտների քանակը:

Նման դեպքում հնարավոր չէ գտնել մի գիծ, որը կանցնի **բոլոր** կետերով: Մեզ պետք է գտնել այնպիսի գիծ, որը կանցնի կետերի «միջով»՝ նվազագույնի հասցնելով ընդհանուր սխալը:



## 2. Ինչպե՞ս է $A^+$ -ը լուծում սա

Գծային ռեգրեսիայի խնդիրը ձևակերպվում է որպես  $Ax = b$ , որտեղ.

- $A$ -ն ձեր տվյալների մատրիցն է (բնութագրերը):
- $x$ -ը այն գործակիցներն են (weights), որոնք մենք ուզում ենք գտնել:
- $b$ -ն թիրախային արժեքներն են (իրական գները):

Քանի որ ճշգրիտ լուծում չկա, մենք օգտագործում ենք նախորդ քայլում քննարկված **լավագույն մոտարկման բանաձևը**.

$$x = A^+b$$

Օգտագործելով SVD վերլուծությունը ( $A^+ = V\Sigma^+U^T$ )՝ համակարգիչը վայրկյանական հաշվում է այն գործակիցները, որոնք **նվազագույնի են հասցնում սխալի քառակուսիների գումարը** ( $\|Ax - b\| \rightarrow \min$ ):

### 3. $A^+$ -ի առավելությունները ռեգրեսիայում

Տվյալների գիտության մեջ  $A^+$ -ի օգտագործումը SVD-ի միջոցով ունի երկու հսկայական առավելություն.

- **Կայունություն (Numerical Stability).** Եթե ձեր տվյալների մեջ կան սյուներ, որոնք իրարից շատ ուժեղ կախված են (multicollinearity), սովորական մեթոդները ձախողվում են: Սակայն SVD-ն «տեսնում է» դա և շատ փոքր եզակի արժեքները ( $\sigma$ ) զրոյացնելով՝ կանխում է սխալները:
- **Ունիվերսալություն.** Այն աշխատում է նույնիսկ եթե մատրիցը հակադարձելի չէ կամ ռանգը լիարժեք չէ:

### Ամփոփում. Ինչու՞ է սա կարևոր ձեզ համար

Այն ամենը, ինչ մենք անցանք՝ սեփական արժեքներ  $\rightarrow$  SVD  $\rightarrow$  Կեղծ հակադարձ, տանում է դեպի սա.

Երբ դուք համակարգչին ասում եք «կառուցիր ռեգրեսիայի մոդել», նա հետևաբանում կատարում է հենց այս մաթեմատիկական գործողությունները՝ տվյալները պատում է  $(V^T)$ , ձգում է  $(\Sigma)$ , նորից պատում է  $(U)$  և վերջում տալիս է ձեզ օպտիմալ  $x$  գործակիցները: