

# (algebra lection). Մատրիցի անկյունագծայնացում և SVD

1. [Մաս 1. Անկյունագծայնացման տեսություն և հատկություններ](#)
2. [Մաս 2. Գործնական վարժություններ \(խնդիր 253\)](#)
3. [Մաս 3. Մատրիցի աստիճանի բարձրացում \(խնդիր 256\)](#)
4. [Մաս 4. Սիմետրիկ մատրիցներ և SVD](#)
5. [Մաս 5. SVD-ի բաղադրիչների հաշվարկը](#)
6. [Մաս 6. Մատրիցի Ռանգը և նրա հատկությունները](#)
7. [Մաս 7. SVD-ի հաշվարկման երկու եղանակները](#)
8. [Մաս 8. Երկրաչափական մեկնաբանություն](#)
9. [Մաս 9. Հավելյալ նշումներ](#)

## Մաս 1. Անկյունագծայնացման տեսություն և հատկություններ

### 1.1. Սահմանում

Մատրիցը կոչվում է անկյունագծայնացվող, եթե այն նման է որևէ անկյունագծային մատրիցի:

Դա նշանակում է, որ գոյություն ունի այնպիսի հակադարձելի  $P$  մատրից, որ՝

$$A = PDP^{-1}$$

որտեղ  $D$ -ն անկյունագծային մատրից է, որի գլխավոր անկյունագծի վրա գրված են  $A$ -ի սեփական արժեքները, իսկ  $P$ -ի սյուները  $A$ -ի սեփական վեկտորներն են:

### 1.2. Նման մատրիցների հատկությունը

Եթե երկու մատրից նման են ( $A \sim B$ ), ապա նրանց սեփական արժեքները նույնն են:

Սա բխում է նրանից, որ նման մատրիցներն ունեն նույն բնութագրիչ բազմանդամը՝  $\det(A - \lambda I) = \det(B - \lambda I)$ :

### 1.3. Հակադարձ մատրիցի սեփական արժեքները

**Պնդում.** Մատրիցի հակադարձի սեփական արժեքները սկզբնական մատրիցի սեփական արժեքների հակադարձներն են:

Ապացույց.

Դիցուք  $A$  մատրիցն ունի  $\lambda$  սեփական արժեք ( $\lambda \neq 0$ ) և  $x$  սեփական վեկտոր.

$$Ax = \lambda x$$

Հավասարման երկու կողմը ձախից բազմապատկենք  $A^{-1}$ -ով (քանի որ  $A$ -ն հակադարձելի է,  $\det A \neq 0$ , ուրեմն  $\lambda \neq 0$ ).

$$A^{-1}(Ax) = A^{-1}(\lambda x)$$

$$(A^{-1}A)x = \lambda(A^{-1}x)$$

$$Ix = \lambda A^{-1}x$$

$$x = \lambda A^{-1}x$$

Բաժանենք  $\lambda$ -ի վրա.

$$A^{-1}x = \frac{1}{\lambda}x$$

Սա նշանակում է, որ  $A^{-1}$ -ի համար  $x$ -ը նույն սեփական վեկտորն է, իսկ սեփական արժեքը՝  $\frac{1}{\lambda}$ :

## Մաս 2. Գործնական վարժություններ (Խնդիր 253)

Պահանջ. Գտնել  $P$  մատրիցը, որը  $A$ -ն բերում է անկյունագծային տեսքի և հաշվել  $P^{-1}AP$  արտադրյալը:

### Օրինակ ա)

$$A = \begin{pmatrix} -14 & 12 \\ -20 & 17 \end{pmatrix}$$

#### 1. Սեփական արժեքներ.

$$\det(A - \lambda I) = (-14 - \lambda)(17 - \lambda) - (-240) = \lambda^2 - 3\lambda + 2 = 0$$

Արմատներն են՝  $\lambda_1 = 1, \lambda_2 = 2$ :

#### 2. Սեփական վեկտորներ.

- $\lambda = 1$ -ի դեպքում համակարգը տալիս է  $x_2 = \frac{5}{4}x_1 \Rightarrow v_1 = \begin{pmatrix} 4 \\ 5 \end{pmatrix}$ :
- $\lambda = 2$ -ի դեպքում համակարգը տալիս է  $x_2 = \frac{4}{3}x_1 \Rightarrow v_2 = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$ :

#### 3. Մատրիցների կազմում.

$$P = \begin{pmatrix} 4 & 3 \\ 5 & 4 \end{pmatrix}, \quad P^{-1} = \begin{pmatrix} 4 & -3 \\ -5 & 4 \end{pmatrix}$$

$$\text{Ստուգում} \quad P^{-1}AP = D = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}:$$

Մատրիցի հակադարձը ( $A^{-1}$ ) գտնելու համար սովորաբար օգտագործվում է երկու հիմնական եղանակ՝ կախված մատրիցի չափից և բարդությունից:

### 1. $2 \times 2$ մատրիցի համար (Բանաձևային եղանակ)

$2 \times 2$  չափի մատրիցների դեպքում օգտագործվում է պարզ պատրաստի բանաձև, ինչը տեսնում ենք ձեր լեկցիայի վարժությունների լուծման մեջ:

Եթե  $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ , ապա հակադարձը հաշվվում է հետևյալ կերպ.

$$A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

**Քայլերը.**

- **Հաշվել որոշիչը ( $\det A$ ):** Այն պետք է զրոյից տարբեր լինի:
- **Փոխել տեղերը.** Գլխավոր անկյունագծի տարրերը ( $a$  և  $d$ ) փոխում են իրենց տեղերը:
- **Փոխել նշանները.** Երկրորդական անկյունագծի տարրերը ( $b$  և  $c$ ) փոխում են իրենց նշանները:
- **Բաժանել որոշիչի վրա.** Ստացված մատրիցի բոլոր տարրերը բազմապատկել  $1/\det(A)$ -ով:

### 2. $n \times n$ մատրիցի համար (Գաուս-ժորդանի մեթոդ)

Ավելի մեծ մատրիցների համար (օրինակ՝  $3 \times 3$ ) լեկցիայի ժամանակ կիրառվել է **Գաուս-ժորդանի օժանդակ մատրիցի մեթոդը**:

**Քայլերը.**

3. **Կազմել կցագրված մատրիցը.** Տրված  $P$  մատրիցի կողքին գրում ենք նույն չափի  $I$  միավոր մատրիցը՝  $[P|I]$ :
4. **Կատարել տողային ձևափոխություններ.** Օգտագործելով տողերի գումարում, հանում կամ բազմապատկում թվով, ձախ կողմում գտնվող  $P$  մատրիցը դարձնել միավոր մատրից ( $I$ ):
5. **Ստանալ պատասխանը.** Երբ ձախ կողմում ստացվում է  $I$ , ապա աջ կողմում ավտոմատ կերպով ձևավորվում է  $P^{-1}$  հակադարձ մատրիցը:

## Օրինակ բ)

$$A = \begin{pmatrix} 1 & 0 \\ 6 & -1 \end{pmatrix}$$

1. **Սեփական արժեքներ.** Եռանկյուն մատրից է, արժեքներն անկյունագծի

վրա են՝  $\lambda_1 = 1, \lambda_2 = -1$ :

## 2. Սեփական վեկտորներ.

- $\lambda = 1 \Rightarrow 6x_1 - 2x_2 = 0 \Rightarrow x_2 = 3x_1 \Rightarrow v_1 = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$ :
- $\lambda = -1 \Rightarrow 2x_1 = 0 \Rightarrow x_1 = 0 \Rightarrow v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ :

## 3. Արդյունք.

$$P = \begin{pmatrix} 1 & 0 \\ 3 & 1 \end{pmatrix}, \quad D = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

## Օրինակ գ)

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \end{pmatrix}$$

### 1. Բնութագրիչ հավասարում.

$$(1 - \lambda)((1 - \lambda)^2 - 1) = (1 - \lambda)(\lambda^2 - 2\lambda) = \lambda(1 - \lambda)(\lambda - 2) = 0$$

Սեփական արժեքներ՝  $\lambda_1 = 0, \lambda_2 = 1, \lambda_3 = 2$ :

### 2. Սեփական վեկտորներ.

- $\lambda = 0 \Rightarrow v_1 = (0, 1, -1)^T$ :
- $\lambda = 1 \Rightarrow v_2 = (1, 0, 0)^T$ :
- $\lambda = 2 \Rightarrow v_3 = (0, 1, 1)^T$ :

### 3. $P^{-1}$ -ի հաշվարկը Գաուս-ժորդանի մեթոդով.

Կցագրված մատրիցը՝  $[P|I] \xrightarrow{R_i \rightarrow \dots} [I|P^{-1}]$ :

$$\text{Ստացվում է } P^{-1} = \begin{pmatrix} 0 & 0.5 & -0.5 \\ 1 & 0 & 0 \\ 0 & 0.5 & 0.5 \end{pmatrix}:$$

## Օրինակ դ) $A = \begin{pmatrix} 2 & 0 & -2 \\ 0 & 3 & 0 \\ 0 & 0 & 3 \end{pmatrix}$

Քանի որ մատրիցը **եռանկյուն** է (ներքևում զրոներ են), սեփական արժեքները միանգամից վերցնում ենք անկյունագծից.

- $\lambda_1 = 2$
- $\lambda_2 = 3$
- $\lambda_3 = 3$

Ունենք  $\lambda = 2$  և  $\lambda = 3$  (կրկնապատիկ):

**Քայլ 2. Սեփական վեկտորները ( $\lambda = 2$ -ի համար)**

Լուծում ենք  $(A - 2I)X = 0$  համակարգը (անկյունագծից հանում ենք 2):

$$\begin{pmatrix} 2-2 & 0 & -2 \\ 0 & 3-2 & 0 \\ 0 & 0 & 3-2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 & 0 & -2 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = 0$$

Գրենք հավասարումները.

1.  $-2x_3 = 0 \Rightarrow x_3 = 0$
2.  $1x_2 = 0 \Rightarrow x_2 = 0$
3.  $1x_3 = 0$  (նույնն է, ինչ առաջինը)

**Վերլուծություն.**

- $x_3$ -ը պարտադիր 0 է:
- $x_2$ -ը պարտադիր 0 է:
- $x_1$ -ի մասին ոչ մի հավասարում չկա (առաջին սյան մեջ 0-ներ են): Ուրեմն  $x_1$ -ը **ազատ** է (կարող է լինել ցանկացած թիվ):

Ընտրում ենք  $x_1 = 1$ :

$$v_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

**Քայլ 3. Սեփական վեկտորները ( $\lambda = 3$ -ի համար) — Ուշադրություն**

Լուծում ենք  $(A - 3I)X = 0$  համակարգը (անկյունագծից հանում ենք 3):

$$\begin{pmatrix} 2-3 & 0 & -2 \\ 0 & 3-3 & 0 \\ 0 & 0 & 3-3 \end{pmatrix} = \begin{pmatrix} -1 & 0 & -2 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Բազմապատկենք վեկտորով՝  $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$ :

Ստանում ենք հավասարումների համակարգը.

1.  $-1x_1 + 0x_2 - 2x_3 = 0 \Rightarrow -x_1 - 2x_3 = 0$
2.  $0 = 0$
3.  $0 = 0$

**Վերլուծություն (Ամենակարևոր մասը).**

Մենք ունենք ընդամենը մեկ իրական պայման՝

$$x_1 = -2x_3$$

Իսկ ի՞նչ է կատարվում  $x_2$ -ի հետ:

Նայեք 2-րդ տողին՝  $0x_1 + 0x_2 + 0x_3 = 0$ : Այս հավասարումը ճիշտ է ցանկացած  $x_2$ -ի համար:

Սա նշանակում է, որ  $x_2$ -ը լիակատար ազատ փոփոխական է (այն կապված չէ ոչ  $x_1$ -ի, ոչ էլ  $x_3$ -ի հետ):

Այսպիսով, մենք ունենք **2 ազատության** (2 ազատ փոփոխական)։

1.  $x_3$ -ը ազատ է (սրանով որոշում ենք  $x_1$ -ը):
2.  $x_2$ -ը ազատ է (ևս ոչ մեկից կախված չէ):

**Ինչպես ստանալ 2 վեկտոր.**

Ընդհանուր լուծումը գրվում է այսպես.

$$X = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} -2x_3 \\ x_2 \\ x_3 \end{pmatrix}$$

Տրոհենք սա երկու մասի՝ առանձնացնելով  $x_2$ -ն ու  $x_3$ -ը.

$$X = x_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} + x_3 \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

Ահա այստեղից էլ դուրս են գալիս մեր երկու անկախ վեկտորները.

- **Վեկտոր 1 ( $v_2$ ):** Վերցնենք  $x_2 = 1, x_3 = 0$ :

$$\Rightarrow \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

- **Վեկտոր 2 ( $v_3$ ):** Վերցնենք  $x_2 = 0, x_3 = 1$ :

$$\Rightarrow \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

### Ամփոփում.

Երկրորդ վեկտորը հայտնվեց, որովհետև մատրիցի ամբողջ 2-րդ տողը զրոյացավ, ինչը թույլ տվեց  $x_2$ -ին լինել ցանկացած թիվ՝ անկախ մյուսներից:

### Մաս 3. Մատրիցի աստիճանի բարձրացում (Խնդիր 256)

Տրված է՝  $A = \begin{pmatrix} 1 & 0 \\ -1 & 2 \end{pmatrix}$ : Պահանջվում է հաշվել  $A^{10}$ :

#### Քայլ 1. Գտնում ենք սեփական արժեքները ( $\lambda$ )

Քանի որ մատրիցը եռանկյուն է (զրոն վերևում է), սեփական արժեքները անկյունագծի թվերն են.

- $\lambda_1 = 1$
- $\lambda_2 = 2$

#### Քայլ 2. Գտնում ենք սեփական վեկտորները ( $P$ մատրիցի համար) ա) $\lambda = 1$ -ի համար.

Լուծում ենք  $(A - 1 \cdot I)X = 0$  հավասարումը:

$$\begin{pmatrix} 1-1 & 0 \\ -1 & 2-1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 0$$

$$-x + y = 0 \Rightarrow x = y:$$

Վերցնենք  $x = 1$ , ուրեմն  $y = 1$ :

Ստացանք վեկտոր  $v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ :

#### բ) $\lambda = 2$ -ի համար.

Լուծում ենք  $(A - 2 \cdot I)X = 0$  հավասարումը:

$$\begin{pmatrix} 1-2 & 0 \\ -1 & 2-2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -1 & 0 \\ -1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 0$$

$$-x = 0 \Rightarrow x = 0: y\text{-ը կարող է լինել ցանկացած թիվ (ազատ է):}$$

Վերցնենք  $y = 1$ :

Ստացանք վեկտոր  $v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ :

#### Քայլ 3. Կազմում ենք $P$ և $D$ մատրիցները

- $P$ -ն կազմում ենք՝ վեկտորները սյուն առ սյուն գրելով ( $v_1$ , հետո  $v_2$ ).

$$P = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}$$

- $D$ -ն կազմում ենք՝ անկյունագծի վրա գրելով սեփական արժեքները (նույն հերթականությամբ՝ 1, հետո 2).

$$D = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

#### Քայլ 4. Գտնում ենք $P^{-1}$ հակադարձ մատրիցը

$2 \times 2$  մատրիցի հակադարձի բանաձևով.

$$\det(P) = 1 \cdot 1 - 0 \cdot 1 = 1$$

Փոխում ենք անկյունագծի տեղերը (1 և 1), փոխում ենք մյուսների նշանները (0 և -1).

$$P^{-1} = \frac{1}{1} \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}$$

#### Քայլ 5. Հաշվում ենք $A^{10}$ -ը (Հիմնական մասը)

Բանաձևն է՝  $A^{10} = P \cdot D^{10} \cdot P^{-1}$

Նախ հաշվենք  $D^{10}$ -ը (ուղղակի թվերը բարձրացնում ենք աստիճան).

$$D^{10} = \begin{pmatrix} 1^{10} & 0 \\ 0 & 2^{10} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1024 \end{pmatrix}$$

Հիմա կատարենք բազմապատկումը՝ **ծախից աջ**:

**Մաս 1.** Հաշվենք  $P \cdot D^{10}$  արտադրյալը.

$$\begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 0 & 1024 \end{pmatrix} = \begin{pmatrix} 1 \cdot 1 + 0 \cdot 0 & 1 \cdot 0 + 0 \cdot 1024 \\ 1 \cdot 1 + 1 \cdot 0 & 1 \cdot 0 + 1 \cdot 1024 \end{pmatrix} \\ = \begin{pmatrix} 1 & 0 \\ 1 & 1024 \end{pmatrix}$$

**Մաս 2.** Ստացվածը բազմապատկենք  $P^{-1}$ -ով.

$$\underbrace{\begin{pmatrix} 1 & 0 \\ 1 & 1024 \end{pmatrix}}_{\text{Արդյունք}} \cdot \underbrace{\begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}}_{P^{-1}}$$

Կատարենք «տողը սյան վրա» բազմապատկումը.

- **Տող 1, Սյուն 1:**  $1 \cdot 1 + 0 \cdot (-1) = 1$
- **Տող 1, Սյուն 2:**  $1 \cdot 0 + 0 \cdot 1 = 0$
- **Տող 2, Սյուն 1:**  $1 \cdot 1 + 1024 \cdot (-1) = 1 - 1024 = -1023$
- **Տող 2, Սյուն 2:**  $1 \cdot 0 + 1024 \cdot 1 = 1024$

**Վերջնական Պատասխան**



$$A^{10} = \begin{pmatrix} 1 & 0 \\ -1023 & 1024 \end{pmatrix}$$

## Մաս 4. Սիմետրիկ մատրիցներ և SVD

### 4.1. Սիմետրիկ մատրիցներ ( $A = A^T$ )

Եթե մատրիցը սիմետրիկ է, ապա այն կարելի է անկյունագծայնացնել **օրթոգոնալ** մատրիցի միջոցով:

Այսինքն՝  $P$  մատրիցը օրթոգոնալ է, ինչը նշանակում է  $P^{-1} = P^T$ :

Հետևաբար բանաձևը դառնում է՝

$$A = PDP^T$$

### 4.2. Մատրիցի Եզակի Արժեքների Վերլուծություն (SVD - Singular Value Decomposition)

Անկյունագծային վերլուծությունը աշխատում է միայն քառակուսի մատրիցների համար ( $n \times n$ ), որոնք ունեն բավարար քանակությամբ անկախ սեփական վեկտորներ:

SVD-ն ավելի ընդհանուր մոտեցում է, որը կիրառելի է **կամայական**  $m \times n$  մատրիցի համար:

#### Թեորեմ (SVD).

Կամայական  $A \in M_{m \times n}$  մատրիցի համար գոյություն ունեն  $U \in M_{m \times m}$ ,  $\Sigma \in M_{m \times n}$  և  $V \in M_{n \times n}$  մատրիցներ այնպես, որ՝

$$A = U\Sigma V^T$$

որտեղ՝

- $U$ -ն և  $V$ -ն օրթոգոնալ մատրիցներ են ( $U^{-1} = U^T$ ,  $V^{-1} = V^T$ ):
- $\Sigma$ -ն (սիգմա) անկյունագծային տեսք ունի (ուղղանկյուն անկյունագծային), որի անկյունագծի վրա  $A$ -ի **եզակի արժեքներն են** ( $\sigma_i$ ):

### 4.3. Ինչպե՞ս գտնել $U$ , $\Sigma$ , $V$ -ն

Մենք օգտագործում ենք  $AA^T$  և  $A^T A$  սիմետրիկ մատրիցները:

- $V$  մատրիցը ստացվում է  $A^T A$ -ի սեփական վեկտորներից:
- $U$  մատրիցը ստացվում է  $AA^T$ -ի սեփական վեկտորներից:
- Եզակի արժեքները** ( $\sigma_i$ ) հավասար են  $A^T A$ -ի սեփական արժեքների քառակուսի արմատներին ( $\sigma_i = \sqrt{\lambda_i}$ ):

## Մաս 5. SVD-ի բաղադրիչների հաշվարկը

$(U, \Sigma, V)$

Մենք գիտենք, որ ցանկացած  $A$  մատրից կարելի է ներկայացնել  $A = U\Sigma V^T$  տեսքով: Հարց է առաջանում՝ ինչպե՞ս գտնել այդ անհայտ մատրիցները: Դրա համար օգտագործում ենք  $A$ -ի և իր տրանսպոզի արտադրյալները:

### 5.1. $V$ մատրիցի և եզակի արժեքների ( $\Sigma$ ) ստացումը՝ $A^T A$ -ի միջոցով

Դիտարկենք  $A^T A$  սիմետրիկ մատրիցը և տեղադրենք  $A$ -ի SVD վերլուծությունը:

#### 1. Տեղադրում.

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T)$$

#### 2. Տրանսպոզի բացում.

Օգտվելով  $(AB)^T = B^T A^T$  հատկությունից՝ առաջին փակագիծը դառնում է  $(V^T)^T \Sigma^T U^T = V \Sigma^T U^T$ :

$$A^T A = V \underbrace{\Sigma^T U^T U}_{I} \Sigma V^T$$

#### 3. Օրթոգոնալության կիրառում.

Քանի որ  $U$ -ն օրթոգոնալ մատրից է, ապա  $U^T U = I$  (միավոր մատրից):

#### 4. Արդյունք.

$$A^T A = V(\Sigma^T \Sigma)V^T$$

Եզրակացություն.

Ստացված հավասարումը՝  $A^T A = V(\Sigma^T \Sigma)V^T$ , իրենից ներկայացնում է  $A^T A$  մատրիցի անկյունագծայնացումը (սպեկտրալ վերլուծությունը):

- $V$ -ի սյուները  $A^T A$  մատրիցի սեփական վեկտորներն են (աջ եզակի վեկտորներ):
- $\Sigma^T \Sigma$  մատրիցը անկյունագծային է, որի տարրերը  $A^T A$ -ի սեփական արժեքներն են:

### 5.2. $U$ մատրիցի ստացումը՝ $AA^T$ -ի միջոցով

Նույն տրամաբանությամբ դիտարկում ենք  $AA^T$  արտադրյալը:

**1. Տեղադրում.**

$$AA^T = (U\Sigma V^T)(U\Sigma V^T)^T$$

**2. Տրանսպոզի բացում.**

$$AA^T = U\Sigma \underbrace{V^T V}_{I} \Sigma^T U^T$$

**3. Օրթոգոնալության կիրառում.**

Քանի որ  $V$ -ն օրթոգոնալ է,  $V^T V = I$ :

**4. Արդյունք.**

$$AA^T = U(\Sigma \Sigma^T)U^T$$

**Եզրակացություն.**

- $U$ -ի սյուները  $AA^T$  մատրիցի սեփական վեկտորներն են (ձախ եզակի վեկտորներ):
- $\Sigma \Sigma^T$ -ը պարունակում է  $AA^T$ -ի սեփական արժեքները:

**5.3. Եզակի արժեքների ( $\sigma$ ) կապը սեփական արժեքների ( $\lambda$ ) հետ**

Ինչ տեսք ունի  $\Sigma^T \Sigma$  մատրիցը:

Գրատախտակին բերված է օրինակ  $3 \times 2$  չափի  $\Sigma$  մատրիցի համար:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix}$$

Բազմապատկելով իր տրանսպոզի հետ՝ ստանում ենք.

$$\Sigma^T \Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}$$

**Կարևոր պնդում.**

$A^T A$  մատրիցի սեփական արժեքները ( $\lambda_i$ ) հավասար են  $A$  մատրիցի եզակի արժեքների քառակուսիներին ( $\sigma_i^2$ ):

Այսինքն՝

$$\sigma_i = \sqrt{\lambda_i(A^T A)}$$

Այստեղ  $\lambda_i(A^T A)$  գրառումը չի նշանակում « $\lambda_i$  թիվը բազմապատկած  $A^T A$  մատրիցով»:

$\lambda_i(M)$  նշանակում է՝ « $M$  մատրիցի  $i$ -րդ սեփական արժեքը»: Սա ֆունկցիայի նման նշանակում է (ինչպես  $f(x)$ -ը):

Հետևաբար, արմատի տակ ոչ թե մատրից է, այլ մի սովորական թիվ (սեփական արժեքը):

Բանաձևը կարդացվում է այսպես. « $A$  մատրիցի  $i$ -րդ եզակի արժեքը ( $\sigma_i$ ) հավասար է  $A^T A$  մատրիցի  $i$ -րդ սեփական արժեքի ( $\lambda_i$ ) քառակուսի արմատին»:

Սա բացատրում է, թե ինչու են SVD-ի մեջ եզակի արժեքները միշտ ոչ բացասական (քառակուսի արմատ են):

## Մաս 6. Մատրիցի Ռանգը և Նրա հատկությունները

Նախքան SVD-ի հաշվարկման նրբություններին անցնելը, պետք է հասկանալ **ռանգի (rank)** գաղափարը, քանի որ հենց դա է որոշում, թե քանի հատ գրոյից տարբեր եզակի արժեք ( $\sigma$ ) ենք ունենալու:

### 6.1. Սահմանում և Տարրական ձևափոխություններ

**Սահմանում.** Մատրիցի **տողային ռանգ** կոչվում է այդ մատրիցի գծորեն անկախ տողերի առավելագույն քանակը:

Նույնը ճիշտ է սյուների համար (սյունային ռանգ):

**Կարևոր Պնդում.** Մատրիցի տարրական ձևափոխությունները (տողերի տեղափոխություն, բազմապատկում թվով, գումարում) **չեն փոխում մատրիցի ռանգը**:

Սա նշանակում է, որ Գաուսի մեթոդով մատրիցը պարզեցնելիս նրա անկախ տողերի քանակը մնում է նույնը:

### 6.2. Ռանգի վերաբերյալ թեորեմներ

- Տրանսպոզի ռանգը.** Մատրիցի և նրա տրանսպոզի ռանգերը հավասար են՝  $\text{rank}(A) = \text{rank}(A^T)$ :
- Արտադրյալի ռանգը.** Երկու մատրիցների արտադրյալի ռանգը չի գերազանցում արտադրիչներից յուրաքանչյուրի ռանգը.

$$\text{rank}(AB) \leq \min(\text{rank}(A), \text{rank}(B))$$

## Թեորեմ (Մատրիցի ռանգի մասին հիմնական թեորեմը)

Կամայական  $A \in M_{m \times n}$  մատրիցի համար նրա սյունային ռանգը հավասար է նրա տողային ռանգին:

$$\text{rank}_{\text{col}}(A) = \text{rank}_{\text{row}}(A)$$

### Ապացույց (Մատրիցների վերլուծության մեթոդով)

#### 1. Ենթադրություն.

Դիցուք  $A$  մատրիցի սյունային ռանգը հավասար է  $r$ -ի ( $\text{rank}_{\text{col}}(A) = r$ ): Սա նշանակում է, որ  $A$ -ի սյունային տարածության բազիսը բաղկացած է  $r$  հատ վեկտորներից:

#### 2. Մատրիցների կառուցում.

Լինեն  $b_1, b_2, \dots, b_r$  վեկտորները  $A$ -ի սյունային տարածության բազիսի տարրերը: Կազմենք  $B \in M_{m \times r}$  մատրիցը, որի սյուները հենց այս բազիսային վեկտորներն են:

Քանի որ  $A$  մատրիցի յուրաքանչյուր  $a_j$  սյուն պատկանում է սյունային տարածությանը, այն կարող է ներկայացվել որպես  $B$ -ի սյուների գծային կոմբինացիա.

$$a_j = c_{1j}b_1 + c_{2j}b_2 + \dots + c_{rj}b_r$$

Սա նշանակում է, որ գոյություն ունի մի  $C \in M_{r \times n}$  մատրից այնպիսին, որ.

$$A = B \cdot C$$

#### 3. Տողային ռանգի գնահատում.

Նայենք այս արտադրյալին տողերի տեսանկյունից: Մատրիցների բազմապատկման սահմանման համաձայն՝  $A$  մատրիցի յուրաքանչյուր տող հանդիսանում է  $C$  մատրիցի տողերի գծային կոմբինացիա:

$$(B \cdot C)_i = \sum_{k=1}^r b_{ik} C_k$$

Քանի որ  $C$  մատրիցն ունի ընդամենը  $r$  **հատ տող**, ապա  $A$ -ի տողային տարածությունը կարող է սպառվել (ծնվել) առավելագույնը  $r$  հատ վեկտորներով: Հետևաբար,  $A$ -ի տողային ռանգը չի կարող գերազանցել  $r$ -ը.

$$\text{rank}_{\text{row}}(A) \leq r = \text{rank}_{\text{col}}(A)$$

#### 4. Հակադարձ անհավասարություն.

Այս նույն տրամաբանությունը կիրառենք  $A^T$  (տրանսպոզացված) մատրիցի համար:

Քանի որ  $\text{rank}_{\text{row}}(A) = \text{rank}_{\text{col}}(A^T)$  և  $\text{rank}_{\text{col}}(A) = \text{rank}_{\text{row}}(A^T)$ , ապա վերևի ապացուցված անհավասարությունից հետևում է.

$$\text{rank}_{\text{col}}(A^T) \leq \text{rank}_{\text{row}}(A^T) \implies \text{rank}_{\text{row}}(A) \leq \text{rank}_{\text{col}}(A)$$

և միաժամանակ՝

$$\text{rank}_{\text{col}}(A) \leq \text{rank}_{\text{row}}(A)$$

## 5. Եզրակացություն.

Քանի որ երկու կողմից ունենք ոչ խիստ անհավասարություններ, միակ հնարավոր տարբերակը դրանց հավասարությունն է.

$$\text{rank}_{\text{row}}(A) = \text{rank}_{\text{col}}(A)$$



## Մաս 7. SVD-ի հաշվարկման երկու եղանակները

Մենք գիտենք, որ  $A = U\Sigma V^T$ : Գործնականում այս վերլուծությունը ստանալու համար կա երկու մոտեցում:

### Եղանակ 1. «Առանձին» հաշվարկ (Դասական մոտեցում)

Սա այն մեթոդն է, որը քննարկեցինք նախորդ մասում:

- Հաշվում ենք  $A^T A$  սիմետրիկ մատրիցը և գտնում նրա սեփական վեկտորները  $\rightarrow$  ստանում ենք  $V$  մատրիցը:
- Հաշվում ենք  $AA^T$  սիմետրիկ մատրիցը և գտնում նրա սեփական վեկտորները  $\rightarrow$  ստանում ենք  $U$  մատրիցը:
- Սեփական արժեքներից ստանում ենք  $\sigma_i = \sqrt{\lambda_i}$  և լցնում  $\Sigma$  մատրիցը:

*Թերությունը.* Եթե մատրիցը շատ մեծ է, երկու անգամ սեփական վեկտորներ հաշվելը երկար գործընթաց է:

### Եղանակ 2. «Կապակցված» հաշվարկ (Ավելի արդյունավետ)

Այս մեթոդը հիմնված է այն բանի վրա, որ  $U$ -ն և  $V$ -ն իրար հետ կապված են: Մենք կարող ենք գտնել մեկը և դրա միջոցով ստանալ մյուսը:

**Քայլ 1.** Գտնում ենք  $V$  մատրիցը (աջ եզակի վեկտորները)՝ լուծելով  $A^T A$ -ի խնդիրը:

**Քայլ 2.** Օգտագործում ենք հետևյալ կապը.

Մենք գիտենք, որ  $AV = U\Sigma$ :

Բացենք սա ըստ սյուների ( $v_i$  և  $u_i$  վեկտորների համար).

$$Av_i = \sigma_i u_i$$

Այստեղից կարող ենք արտահայտել  $u_i$ -ն.

$$u_i = \frac{1}{\sigma_i} Av_i$$

**Ինչու՞ է սա կարևոր (Ռանգի դերը):**

Այս բանաձևը աշխատում է միայն այն դեպքում, երբ  $\sigma_i \neq 0$ :


- Եթե մատրիցի ռանգը  $r$  է, ապա մենք ունենք  $r$  հատ զրոյից տարբեր  $\sigma_i$ :
- Այս բանաձևով մենք կարող ենք գտնել  $U$  մատրիցի առաջին  $r$  հատ սյուները:

**Ի՞նչ անել մնացած սյուների հետ (Զրոյական տողերի/սյուների խնդիրը).**

Եթե  $U$  մատրիցը պետք է լինի  $m \times m$  չափի, բայց մենք գտել ենք ընդամենը  $r$  հատ սյուն (որտեղ  $r < m$ ), մնացած  $m - r$  սյուները պետք է լրացնել այնպես, որ  $U$ -ն մնա **օրթոգոնալ**:

- Այս լրացուցիչ սյուները ընտրվում են  $A^T$ -ի զրոյական ենթատարածությունից (kernel):
- Դրանք պետք է լինեն ուղղահայաց արդեն գտնված  $u_1, \dots, u_r$  վեկտորներին: Սա հենց այն մասն է, որ նշեցիք՝ «պետք է առանձին աշխատենք»:

## Մաս 8. Երկրաչափական մեկնաբանություն



Նկարում պատկերված է SVD-ի գեղեցիկ երկրաչափական իմաստը: Այն ցույց է տալիս, թե ինչպես է կամայական  $A$  մատրիցը ձևափոխում տարածությունը՝ այն բաժանելով երեք պարզ քայլերի:

Ըստ բանաձևի՝  $A = U\Sigma V^T$ : Պատկերը ցույց է տալիս այս գործողությունների հաջորդականությունը ձախից աջ.

### 1. Պտույտ ( $V^T$ մատրից).

- Սկզբնական փոխում ունենք միավոր շրջանագիծ՝ ստանդարտ բազիսային վեկտորներով ( $v_1, v_2$ ):
- $V^T$  գործողությունը պտտում է այս վեկտորները այնպես, որ նրանք համընկնեն մատրիցի «բնական» առանցքների հետ:  $V$ -ի սյուները  $A^T A$  մատրիցի սեփական վեկտորներն են:

### 2. Ձգում ( $\Sigma$ մատրից).

- Սա վերլուծության միակ քայլն է, որը փոխում է վեկտորների երկարությունը:
- Շրջանագիծը վերածվում է **Էլիպսի**: Առանցքները ձգվում են  $\sigma_1$  և  $\sigma_2$  գործակիցներով, որոնք կոչվում են **եզակի արժեքներ**:
- Հիշենք, որ  $\sigma_i = \sqrt{\lambda_i(A^T A)}$ :

### 3. Վերջնական պտույտ ( $U$ մատրից).

- Ստացված Էլիպսը պտտվում է նոր կոորդինատային համակարգում:
- $U$ -ի սյուները ( $u_1, u_2$ ) հանդիսանում են  $AA^T$  մատրիցի սեփական վեկտորները:

## Ինչու է սա կարևոր

- **Տվյալների սեղմում**. Մեծ  $\sigma$  արժեքները ցույց են տալիս տվյալների ամենակարևոր ուղղությունները: Փոքր  $\sigma$ -ները զրոյացնելով՝ կարելի է սեղմել պատկերները կամ տվյալները՝ առանց էական կորուստների:
- **Մատրիցի ռանգ**. Չրոյից տարբեր  $\sigma$  արժեքների քանակը ճշգրիտ ցույց է տալիս մատրիցի ռանգը:



- **Կայունություն.** Ի տարբերություն սովորական անկյունագծայնացման ( $A = PDP^{-1}$ ), որը պահանջում է քառակուսի մատրից և անկախ սեփական վեկտորներ, SVD-ն հնարավոր է իրականացնել **ցանկացած** մատրիցի համար:

**Ահա երեք պատճառ, թե ինչու է հենց  $A^T A$ -ն պատասխանատու  $V$  մատրիցի (մուտքային ուղղությունների) համար.**

Պատկերացրեք, դուք ունեք մի վեկտոր  $x$  և ուզում եք իմանալ, թե  $A$  մատրիցն այն ինչքանով է **երկարացնում**: Մեզ հետաքրքիր է արդյունքի ( $Ax$ ) երկարության քառակուսին.

$$\|Ax\|^2 = (Ax)^T(Ax) = x^T(A^T A)x$$

Տեսնում եք,  $A^T A$ -ն հայտնվեց հենց այնտեղ, որտեղ մենք չափում ենք, թե ինչ է անում  $A$ -ն վեկտորի **երկարության** հետ:

- $A^T A$ -ի սեփական վեկտորները ( $V$ ) այն ուղղություններն են, որոնցով  $A$ -ն **առավելագույն** կամ **նվազագույն** ձգումն է կատարում:
- Այդ պատճառով  $V$ -ն կոչվում է «մուտքային բազիս»՝ այն ցույց է տալիս, թե  $A$ -ի համար ո՞ր ուղղություններն են կարևոր:

## 2. «Այնտեղ և հետ» սկզբունքը

$A$  մատրիցը վեկտորը տանում է մի աշխարհից մյուսը ( $x \rightarrow Ax$ ): Բայց մենք չենք կարող խոսել սեփական վեկտորների մասին, եթե վեկտորը չի վերադառնում նույն աշխարհ:

- $A$ -ն տանում է վեկտորը «թիրախային» տարածություն:
- $A^T$ -ն այն հետ է բերում «մեկնարկային» տարածություն:

Երբ մենք հաշվում ենք  $A^T A$ , մենք հարցնում ենք. «Ո՞ր ուղղություններն են, որոնք այնտեղ գնալուց և հետ գալուց հետո **չեն փոխում իրենց ուղղությունը** (միայն երկարությունն է փոխվում)»: Դրանք հենց  $A^T A$ -ի սեփական վեկտորներն են:

## 3. Մաթեմատիկական «գտնումը» (Cancellation)

Եթե նայենք հանրահաշվորեն,  $A = U\Sigma V^T$  վերլուծության մեջ  $U$ -ն պատասխանատու է «ելքային» պտույտի համար, իսկ  $V$ -ն՝ «մուտքային»: Երբ մենք հաշվում ենք  $A^T A$ , մենք «չեզոքացնում» ենք  $U$ -ն.

1.  $A^T A = (V\Sigma^T U^T)(U\Sigma V^T)$ :
2. Քանի որ  $U$ -ն օրթոգոնալ է,  $U^T U = I$  (այն անհետանում է):
3. Մնում է միայն  $V\Sigma^T \Sigma V^T$ :

Սա նշանակում է, որ  $A^T A$ -ն **չի տեսնում  $U$ -ին**: Այն կենտրոնանում է միայն  $V$ -ի և ձգումների ( $\Sigma$ ) վրա: Դա նման է նրան, որ դուք պտտեք մի գունդ, ձգեք այն, ու հետո էլի պտտեք: Եթե ուզում եք իմանալ միայն ձգման ուղղությունները, վերջին պտույտը ( $U$ ) ձեզ պետք չէ:

### Ամփոփում

- $V$  (**աջ եզակի վեկտորները**) գալիս են  $A^T A$ -ից, որովհետև դրանք բնութագրում են **մուտքային** տարածության այն ուղղությունները, որոնք  $A$ -ն ամենաշատն է ձգում:
- $U$  (**ձախ եզակի վեկտորները**) գալիս են  $AA^T$ -ից, որովհետև դրանք բնութագրում են, թե այդ ձգված ուղղությունները **ուր են հասել** ելքային տարածության մեջ:

Ե> կեք դիտարկենք այս օրինակը և տեսնենք, թե ինչպես է  $\|Ax\|^2$  «Էներգիան» կամ ձգման չափը փոփոխվում տարբեր ուղղությունների վրա:

Հիշեցնենք մեր  $A$  մատրիցը և նրա  $A^T A$  արտադրյալը.

$$A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}, \quad A^T A = \begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix}$$

$A^T A$ -ի սեփական արժեքները և վեկտորները.

- $\lambda_1 = 45$  համապատասխանող  $v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$  վեկտորին:
- $\lambda_2 = 5$  համապատասխանող  $v_2 = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$  վեկտորին:

### 1. Ստուգում $v_1$ ուղղության վրա (Առավելագույն ձգում)

Եկեք տեսնենք, թե ինչ է անում  $A$  մատրիցը առաջին սեփական վեկտորի հետ.

$$Av_1 = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 3/\sqrt{2} \\ 9/\sqrt{2} \end{pmatrix}$$

Հաշվենք արդյունքի երկարության քառակուսին.

$$\|Av_1\|^2 = \left(\frac{3}{\sqrt{2}}\right)^2 + \left(\frac{9}{\sqrt{2}}\right)^2 = \frac{9}{2} + \frac{81}{2} = \frac{90}{2} = 45$$

**Ինտուիտիվ նկատառում.** Ստացված թիվը ճշգրիտ հավասար է  $\lambda_1$ -ին: Սա նշանակում է, որ  $v_1$  ուղղությամբ վեկտորը ձգվում է  $\sqrt{45} \approx 6.7$  անգամ:

## 2. Ստուգում $v_2$ ուղղության վրա (Նվազագույն ձգում)

Այժմ փորձենք երկրորդ սեփական վեկտորը.

$$Av_2 = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} -3/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

Հաշվենք երկարության քառակուսին.

$$\|Av_2\|^2 = \left(\frac{-3}{\sqrt{2}}\right)^2 + \left(\frac{1}{\sqrt{2}}\right)^2 = \frac{9}{2} + \frac{1}{2} = \frac{10}{2} = 5$$

**Ինտուիտիվ նկատառում.** Արդյունքը հավասար է  $\lambda_2$ -ին: Այս ուղղությամբ մատրիցը շատ ավելի թույլ է ձգում վեկտորը՝ ընդամենը  $\sqrt{5} \approx 2.2$  անգամ:

## Եզրակացություն. Ինչու՞ $A^T A$

Այս օրինակը ցույց է տալիս, որ  $A^T A$  մատրիցը հանդես է գալիս որպես «ուղղությունների գտիչ».

- Եթե մենք վերցնեինք ցանկացած այլ միավոր վեկտոր  $x$  (որը  $v_1$  կամ  $v_2$  չէ), ապա  $\|Ax\|^2$  արժեքը կլիներ 5-ի և 45-ի միջև:
- $A^T A$ -ի սեփական վեկտորները ( $V$  մատրիցի սյուները) այն **կրիտիկական ուղղություններն են**, որոնք բացահայտում են մատրիցի ամբողջական ուժը կամ թուլությունը:
- Հենց այդ պատճառով SVD-ն կառուցելիս մենք սկսում ենք  $A^T A$ -ից՝ մենք ուզում ենք գտնել այն առանցքները, որոնց երկայնքով մատրիցը կատարում է իր հիմնական «աշխատանքը»:

Այսինքն,  $V$  մատրիցը մեզ տալիս է **էլիպսի առանցքների ուղղությունները** նախքան պտտվելը, իսկ  $U$  մատրիցը ցույց է տալիս, թե այդ առանցքները որտեղ են հայտնվում ձևափոխությունից հետո:

## 1. Որտեղի՞ց ենք ստանում $u_i = \frac{1}{\sigma_i} Av_i$ բանաձևը

Այս բանաձևը օդից չի ընկել, այն ուղղակիորեն բխում է SVD-ի հիմնական հավասարումից: Եկեք դուրս բերենք այն քայլ առ քայլ.

1. Գրենք SVD-ի հիմնական բանաձևը.

$$A = U \Sigma V^T$$

2. Երկու կողմը աջից բազմապատկենք  $V$ -ով (հիշելով, որ  $V^T V = I$ , քանի որ  $V$ -ն օրթոգոնալ է).

$$AV = U \underbrace{\Sigma V^T V}_I$$

$$AV = U\Sigma$$

3. Հիմա նայենք այս հավասարմանը **սյուն առ սյուն**:

- Ձախ կողմում  $A$  անգամ  $V$ -ի  $i$ -րդ սյուն ( $v_i$ ):
- Աջ կողմում  $U$ -ի  $i$ -րդ սյուն ( $u_i$ ) բազմապատկած  $\Sigma$ -ի անկյունագծի  $i$ -րդ թվով ( $\sigma_i$ ):

$$Av_i = \sigma_i u_i$$

4. Այստեղից էլ գտնում ենք  $u_i$ -ն (բաժանելով  $\sigma_i$ -ի).

$$u_i = \frac{1}{\sigma_i} Av_i$$

**Ինտուիտիվ իմաստը.** Այս բանաձևն ասում է՝ «Եթե  $v_i$  վեկտորը մտցնենք  $A$  մեքենայի մեջ ( $Av_i$ ), մենք կստանանք  $u_i$  ուղղությունը, բայց  $\sigma_i$  անգամ ձգված: Որպեսզի ստանանք մաքուր  $u_i$  (որի երկարությունը 1 է), պետք է արդյունքը բաժանենք ձգման գործակցի ( $\sigma_i$ ) վրա»:

## 2. Ինչու՞ պետք է $U$ և $V$ մատրիցները լինեն օրթոգոնալ

Սա SVD-ի գեղեցկությունն է:

**ա) Ի՞նչ է նշանակում օրթոգոնալ մատրից:**

Օրթոգոնալ մատրիցը ( $Q^T = Q^{-1}$ ) երկրաչափորեն նշանակում է **Պտույտ (Rotation)** կամ **Հայելային արտացոլում**:

Այն ունի երկու կարևոր հատկություն.

1. **Չի փոխում երկարությունը.** Նա ոչինչ չի ձգում և չի սեղմում: Նա միայն պտտում է օբյեկտը:
2. **Չի աղավաղում անկյունները.** Նրա սյունները (առանցքները) միշտ մնում են իրար ուղղահայաց ( $90^\circ$ ):

**բ) Ինչու՞ դրանք պետք է լինեն օրթոգոնալ SVD-ում:**

Մենք ուզում ենք  $A$  մատրիցի բարդ գործողությունը բաժանել պարզ, հասկանալի մասերի:

$$A = \underbrace{U}_{\text{Պտույտ}} \cdot \underbrace{\Sigma}_{\text{Ձգում}} \cdot \underbrace{V^T}_{\text{Պտույտ}}$$

- Եթե  $U$ -ն և  $V$ -ն օրթոգոնալ չլինեին, նրանք նույնպես կձգեին կամ կսեղմեին տարածությունը:
- Այդ դեպքում  $\Sigma$ -ն չէր լինի միակ պատասխանատուն «ձգման» համար, և մենք չէինք իմանա՝ իրականում որքան է մատրիցի ուժը ( $\sigma$ ):
- Օրթոգոնալությունը երաշխավորում է, որ մենք ընտրում ենք կոշտ, չաղավաղված կոորդինատային համակարգ (grid): Մենք պտտում ենք ցանցը ( $V$ ), ձգում ենք այն ( $\Sigma$ ), և նորից պտտում ( $U$ ), բայց ցանցի առանցքները երբեք չեն ծռվում:

### 3. SVD-ն և Պատկերների Սեղմումը (Image Compression)

Սա SVD-ի ամենատպալորիչ կիրառությունն է: Եկեք տեսնենք, թե ինչպես է դա աշխատում:

#### Գաղափարը.

Համակարգչի համար նկարը պարզապես թվերի մատրից է (օրինակ՝ սև-սպիտակ նկարում յուրաքանչյուր թիվ ցույց է տալիս պիքսելի պայծառությունը):

Երբ մենք անում ենք SVD ( $A = U\Sigma V^T$ ), մենք կարող ենք մատրիցը գրել որպես գումար.

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \sigma_3 u_3 v_3^T + \dots + \sigma_n u_n v_n^T$$

- $\sigma_1$  (**Ամենամեծը**): Պարունակում է նկարի հիմնական ինֆորմացիան (ուրվագծերը, մեծ լույսերը):
- $\sigma_{50}$  (**Փոքրը**): Պարունակում է մանր դետալները:
- $\sigma_n$  (**Շատ փոքր**): Պարունակում է աղմուկ (noise) կամ անկարևոր ինֆորմացիա:

#### Սեղմում (Compression):

Մեզ պետք են բոլորը: Ոչ:

Մենք կարող ենք վերցնել միայն առաջին մի քանի հատը (ասենք՝ առաջին 20-ը կամ 50-ը) և դեն նետել մնացածը:

$$A_{\text{compressed}} \approx \sigma_1 u_1 v_1^T + \dots + \sigma_{50} u_{50} v_{50}^T$$

Ինչու՞ է սա խնայում տեղ:

Պատկերացրեք ունենալ  $1000 \times 1000$  չափի նկար (1,000,000 թիվ):


Եթե պահենք միայն առաջին 50 եզակի արժեքները ( $k = 50$ ).

- $U$ :  $1000 \times 50$  թիվ
- $V$ :  $50 \times 1000$  թիվ
- $\Sigma$ : 50 թիվ
- Ընդամենը՝  $\approx 100,000$  թիվ: **Արդյունք**: Մենք սեղմեցինք նկարը **10 անգամ**, բայց աչքը գրեթե չի նկատի տարբերությունը, քանի որ մենք պահպանեցինք ամենամեծ  $\sigma$ -ները (կարևոր ինֆորմացիան):

**Ամփոփում.** SVD-ն թույլ է տալիս առանձնացնել նկարի «կարևոր» շերտերը «աննշան» շերտերից և պահել միայն կարևորը:

Այսինքն՝ ցանկացած գծային ձևափոխություն կարելի է պատկերացնել որպես՝ **Պտույտ**  $\rightarrow$  **Ձգում**  $\rightarrow$  **Պտույտ**:

## SVD and Rank-**k** approximations



## Մաս 9. Հավելյալ նշումներ

- **Սիմետրիկ մատրիցներ.** Եթե  $A$ -ն սիմետրիկ է, նրա սեփական վեկտորները արդեն իսկ **օրթոգոնալ** են: Սա հեշտացնում է գործը, քանի որ SVD-ի դեպքում  $U$  և  $V$  մատրիցները դառնում են իրար շատ նման (կամ նույնը, նշանի ճշտությամբ):
- **Սիզմա մատրիցի դասավորությունը.**  $\Sigma$  մատրիցի անկյունագծի վրա եզակի արժեքները ( $\sigma_i$ ) միշտ դասավորվում են **նվազման** կարգով (մեծից փոքր),

ինչը թույլ է տալիս առանձնացնել մատրիցի «կարևոր» մասը (մեծ  $\sigma$ -ները)  
«աղմուկից» (փոքր կամ զրոյական  $\sigma$ -ները):